研究设计：知识生产与知识消费的不对称冲击

论文标题： Asymmetric Disruption of Knowledge Consumption and Production by Generative AI: Evidence from Stack Overflow and GitHub (2018–2026)

中文标题： 生成式AI对知识消费与知识生产的不对称冲击：来自Stack Overflow与GitHub的证据（2018—2026）

目标期刊： Nature Human Behaviour / PNAS / MIS Quarterly

一、核心研究问题

> 生成式**AI**工具的普及，是否对人类数字知识生态中的知识消费（**Stack Overflow**问答）和知识生产（**GitHub**开源协作）产生了方向相反的不对称冲击？

1.1 概念定义

知识消费： 遇到问题时主动寻求他人已有知识的行为。 - 操作化：在Stack Overflow发起提问 - 本质：信息检索与获取，AI可直接替代

知识生产： 主动创造、贡献和维护新知识的行为。 - 操作化：在GitHub创建新仓库、发起Issue、提交PR - 本质：创造与协作，AI只能辅助，难以完全替代

1.2 核心假说

H1（总量不对称）： ChatGPT发布后，SO提问量显著下降，而GitHub知识生产活动稳定甚至上升，形成"剪刀差"。

H2（技术域异质性）： AI可替代性越高的编程语言（Python/JS），SO下降越多；但GitHub生产端无此差异，或差异显著小于消费端。

H3（用户分层）： 新手用户（低声誉）的知识消费最先被替代；资深用户（高声誉）的知识生产被AI增强。

H4（知识类型演化）： How-to类问题消失最快（韧性最低），Architecture类最慢（韧性最高）。

H5（知识免疫性）： AI发布后，SO存活问题的平均复杂度显著上升。

二、数据来源

2.1 知识消费端：Stack Overflow

数据	状态	规模	路径
每周提问量×14语言	□完成	424周×14语言	results/api_cache_weekly.json
Posts全文Parquet	□完成	2191万行×11列	data/parquet/posts_2018plus.parquet
API Key	有效	10000次/天	rl_4L6CL2TNw1KLXeYnWRu3SQRt3

14种编程语言（按**AI**可替代性排序）：

语言	**ARI**	组别
Python	0.92	高（>0.80）
JavaScript	0.88	高
TypeScript	0.85	高
Java	0.81	高
C#	0.79	中高（0.60-0.80）
Go	0.72	中高
Ruby	0.65	中高
C++	0.63	中高
C	0.60	中高
R	0.58	中高
Rust	0.35	低（<0.40）
Haskell	0.25	

语言	ARI	组别
		低
Fortran	0.18	低
Assembly	0.10	低

2.2 知识生产端：GitHub

数据	状态	规模	路径
每月新仓库×14语言	□ 70/99月	2018-2023.10	results/github_cache_weekly.json
每月新Issue×14语言	□同上	同上	同上

5个GitHub Token轮换，预计30分钟内完成全部99个月数据。

2.3 对照社区

数据	状态	规模
Math SE每周提问量	□完成	424周
Physics SE每周提问量	□完成	424周

注意： Math SE(-60.9%)和Physics SE(-47.9%)的下降幅度与SO(-58.9%)相近，说明AI冲击不只限于编程领域——这强化了论文的意义，但削弱了这两者作为"不受AI影响的对照组"的作用。改用烹饪**(cooking)**等生活技能社区作为对照。

2.4 控制变量（20个）

已构建完成（**results/control_variables.csv**）：

类别	变量
COVID效应	covid_peak, post_covid
科技裁员	tech_layoff_wave1/2, tech_layoff
SO平台政策	so_ai_ban, so_strike, so_api_restrict

类别	变量
AI工具节点（9个）	post_copilot_beta/ga, post_chatgpt, post_gpt4, post_llama2, post_codelllama, post_claude3, post_gpt4o, post_cursor_boom
AI能力连续指数	ai_capability_index (0.10→0.97)

2.5 Google Trends

7个关键词搜索热度（results/google_trends.csv）： ChatGPT、GitHub Copilot、Stack Overflow、AI coding、Claude AI、Cursor IDE

三、主分析：堆叠面板DID

3.1 数据结构

将SO和GitHub数据竖向堆叠，构建三维面板：

```
单位：编程语言l × 月t × 平台p（SO=0, GitHub=1）
时间：2018-01 → 2026-02（月度，SO聚合到月）
观测数：14语言 × 99月 × 2平台 = 2,772个观测
```

3.2 核心回归方程（**H1**检验）

$$Y_{ltp} = \alpha + \beta_1 (ARI_l \times Post_t) + \beta_2 (ARI_l \times Post_t \times GitHub_p) + \gamma_l + \delta_t + \mu_p + \lambda_{lp} + \mathbf{X}t'\boldsymbol{\theta} + \varepsilon{ltp} $$

其中： - Y_{ltp}：语言l在月t平台p的知识活动量（取对数） - ARI_l：语言l的AI可替代性指数（0-1连续变量） - $Post_t$：ChatGPT发布后虚拟变量（2022年12月起=1） - $GitHub_p$：GitHub平台虚拟变量（GitHub=1，SO=0） - β_1：AI对SO端的处理效应（预期<0） - β_2：不对称系数（**H1**核心，预期**>0**） - $\gamma_l, \delta_t, \mu_p, \lambda_{lp}$：语言/时间/平台/语言×平台固定效应 - $\mathbf{X}_t$：控制变量向量（COVID、裁员、SO政策、AI普及率）

解读： - $\beta_1 < 0$：AI对SO产生负向冲击 - $\beta_1 + \beta_2 \approx 0$ 或 > 0：AI对GitHub无负向冲击 - $\beta_2 > 0$ 且显著：不对称效应成立（**H1**）

3.3 扩展模型（**H2**，异质性）

$$Y_{ltp} = \alpha + \sum_{k} \beta_{1k} (G_k \times Post_t) + \sum_{k} \beta_{2k} (G_k \times Post_t \times GitHub_p) + FE + \mathbf{X}t'\boldsymbol{\theta} + \varepsilon{ltp}$$

其中 G_k 为语言按ARI分组的虚拟变量（高/中/低），检验各组的不对称程度是否随ARI递增。

四、稳健性检验（**6**类）

4.1 平行趋势检验

事件研究图中，$\tau < 0$ 的系数应统计不显著（即ChatGPT发布前SO和GitHub的趋势差异应与ARI无关）。

4.2 Placebo Test

用ChatGPT发布前1年（2021年11月）作为虚假断点，重复主分析，预期β_2不显著。

4.3 Staggered DID（**Callaway & Sant'Anna 2021**）

处理多个AI工具节点（Copilot GA / ChatGPT / GPT-4 / Llama 2），估计各节点的ATT(g,t)，检验冲击是否在累积。

4.4 对照社区检验

用烹饪社区（Cooking SE）的数据替换GitHub，烹饪社区不应有"不对称效应"（两端都稳定）。

4.5 分组稳健性

- 排除COVID时期（2020-2021年）后重跑
- 分2022年前/后两个子样本

4.6 SUR联立方程

用Seemingly Unrelated Regression分别估计SO和GitHub的方程，用Wald检验两个β_1系数的差异是否显著。

五、事件研究设计

对每个主要AI工具节点分别估计：

$$Y_{ltp} = \alpha + \sum_{\tau=-24}^{24} \beta_{\tau} (ARI_l \times \mathbf{1}[t = event + \tau] \times Platform_p) + FE + \varepsilon$$

可视化： 在同一张图上画SO端和GitHub端的 $\hat{\beta}_{\tau}$ 曲线，对比两条响应曲线的形态差异。

六、论文图表规划

图	内容	验证假说
Figure 1	SO vs GitHub剪刀差（月度，标准化=100）	H1
Figure 2	事件研究图（4个AI节点，SO/GitHub叠加）	H1/H5
Figure 3	14语言DID系数图（$\hat{\beta}_1$ by ARI）	H2
Figure 4	不对称系数 $\hat{\beta}_2$ 分语言/分节点	H1/H2
Figure 5	用户分层：新手vs资深的活跃度变化	H3
Figure 6	知识类型演化：How-to类占比时序	H4
Figure 7	知识复杂度指数：ChatGPT前后断点回归	H5
Figure 8	平行趋势检验 + Placebo	稳健性

七、数据处理流程

```
SO API数据（已完成）     GitHub API数据（进行中）
        ↓                                ↓
  api_cache_weekly.json      github_cache_weekly.json
        ↓                                ↓
月度聚合（SO周→月）     已是月度数据
```

```
        ↓                                   ↓
        └──────────── 堆叠合并 ────────────┘
                          ↓
              stacked_panel.csv
                          ↓
    主分析：DID回归（R/Stata/Python）
                          ↓
    稳健性检验 → 事件研究 → 文本分析
                          ↓
    论文图表 + 结果表格
```

八、当前数据状态

数据	完成度	预计完成
SO 14语言424周	□100%	已完成
SO Posts Parquet	□100%	已完成（497MB）
控制变量20个	□100%	已完成
Google Trends	□100%	已完成
GitHub 14语言99月	□70%	30分钟
Math/Physics SE对照	□100%	已完成
跨领域12站点	□25%	20分钟

九、研究时间线

阶段	任务	时间
数据完善	GitHub完整99月	今天
数据处理	堆叠面板构建	1周
主分析	DID + 事件研究	2-3周
文本分析	H4/H5（Parquet）	2-3周
写作	论文撰写	4-6周
合计		约**3**个月